


EJERCICIO BIG DATA 19-5 BANK MARKETING

1) Carga y Exploración - EDA



La variable objetivo **y** presenta una distribución claramente desbalanceada: la gran mayoría de los casos corresponden a la categoría “no”, mientras que sólo una proporción mucho menor pertenece a “yes”. Esto indica que, en el dataset, la mayoría de los clientes no aceptó la propuesta o producto ofrecido.


Entre las variables predictoras más relevantes aparece **age**, donde se observa que los clientes de edades intermedias (aproximadamente entre 25 y 60 años) tienen una probabilidad mucho mayor de responder “no”, mientras que en edades más avanzadas (especialmente mayores de 75 años) aumenta considerablemente la proporción de respuestas “yes”.

Otra variable importante es **poutcome** (resultado de campañas previas), ya que los clientes con resultado previo “**success**” muestran una alta probabilidad de responder “yes” en la campaña actual, mientras que aquellos con resultados “failure” o “nonexistent” presentan predominantemente respuestas “no”. Esto sugiere que el éxito en contactos anteriores influye fuertemente en la probabilidad de aceptación futura.

Entregables y Preguntas de Análisis:

1. Tabla de métricas - Test and Score

A partir de la tabla de evaluación, los resultados muestran que los tres modelos obtienen desempeños relativamente buenos, aunque existen diferencias importantes entre ellos.




Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.924	0.905	0.892	0.890	0.905	0.418
Naive Bayes	0.814	0.819	0.842	0.882	0.819	0.373
Logistic Regression	0.927	0.914	0.905	0.904	0.914	0.497

El modelo que obtuvo el **mejor AUC** fue **Logistic Regression** con un valor de **0.927**, superando levemente a Random Forest. Esto indica que es el modelo con mayor capacidad para distinguir correctamente entre las clases “yes” y “no”.

Además, **Logistic Regression** también alcanzó el **mejor F1-score (0.905)**, lo que refleja un mejor equilibrio entre precisión (Precision) y Recall. Por lo tanto, considerando ambas métricas, la Regresión Logística aparece como el modelo de mejor rendimiento general.

2. Matriz de Confusión - Regresión Logística

Tomando la matriz de confusión correspondiente a **Logistic Regression**, se identifican los siguientes valores:




De allí se obtienen:

- **TN (True Negatives) = 2853**
Casos “no” correctamente clasificados como “no”
- **FP (False Positives) = 77**
Casos “no” clasificados incorrectamente como “yes”
- **FN (False Negatives) = 207**
Casos “yes” clasificados incorrectamente como “no”
- **TP (True Positives) = 159**
Casos “yes” correctamente identificados

El modelo logra clasificar muy bien la clase mayoritaria (“no”), aunque presenta más dificultades para detectar correctamente la clase minoritaria (“yes”), algo esperable dado el desbalance observado en la variable objetivo.

3. Análisis de la Curva ROC

La curva ROC muestra la relación entre la **Tasa de Verdaderos Positivos (TPR)** y la **Tasa de Falsos Positivos (FPR)** para cada modelo.



En el gráfico puede observarse que:

- **Logistic Regression** y **Random Forest** presentan curvas muy superiores a la diagonal aleatoria y bastante cercanas al vértice superior izquierdo, lo que indica un excelente desempeño. (Relacionado directamente con el AUC)
- **Naive Bayes** queda claramente por debajo de los otros dos modelos, mostrando menor capacidad discriminativa.

Entre los tres modelos, **Logistic Regression exhibe la mejor relación entre TPR y FPR**, ya que su curva se mantiene ligeramente por encima de las demás durante gran parte del recorrido. Esto significa que consigue una mayor tasa de verdaderos positivos sin incrementar demasiado los falsos positivos.

Este resultado es consistente con el valor de **AUC más alto (0.927)** obtenido en el Test and Score, confirmando que la Regresión Logística es el modelo con mejor capacidad predictiva global para este problema.