


EJERCICIO EN CLASE BIG DATA: ANÁLISIS PREDICTIVO **CON EL TITANIC**


PIPELINE DEL ORANGE:



Respuesta a las preguntas:

PASO 2:

Pregunta: ¿Se cumple visualmente la regla de "mujeres y niños primero"?



Respuesta:

Como se puede observar en el gráfico, se cumple la regla de mujeres y niños primero ya que la proporción de mujeres que sobrevivieron es mayor a la de los hombres.


Pregunta: ¿Los pasajeros que pagaron una tarifa más alta tuvieron más chances de sobrevivir?



Respuesta:

Se observa que hay relación entre la tarifa pagada y la supervivencia, los pasajeros con tarifas más elevadas tienden a concentrar una mayor proporción de sobrevivientes.

Pregunta: ¿Existen valores atípicos (outliers) en la edad de los sobrevivientes?




Respuesta:

Sí, existen posibles valores atípicos en la edad de los sobrevivientes, principalmente en el extremo superior. La mayoría de los sobrevivientes se concentra entre aproximadamente 19 y 36 años, pero aparecen algunos casos con edades mucho más altas, cercanas a los 70 u 80 años.

PASO 5:


Pregunta: ¿Cuál es el valor de CA obtenido? ¿Cómo lo interpretarían en términos de "predicciones correctas totales"?

Reflexión: Si el CA es de 0.79, ¿el modelo es "bueno" o depende del contexto?



Respuesta:

El CA obtenido es de 0.796. Esto significa que el modelo logró clasificar correctamente aproximadamente el 79,6% de los pasajeros, distinguiendo entre quienes sobrevivieron y quienes no sobrevivieron. En otras palabras, cerca de 8 de cada 10 predicciones realizadas por el modelo fueron correctas.



Respuesta:

Para la reflexión, adjuntamos un screenshot de la variable Survived en Distributions.

Es importante entender que el desbalance en las clases afecta el resultado del modelo. El hecho de que el CA sea alto es bueno por sí solo, pero esto se puede deber justamente a que, como se observa, la clase=0 es más frecuente que la clase=1. Como ejemplo, un modelo que siempre diera como resultado que no sobrevivió, tendría un CA cercano al 60%. Por eso, el CA debe complementarse con métricas como Precision, Recall, F1, AUC y la matriz de confusión.


PASO 6:

Falsos Positivos (FP): El modelo predijo que sobrevivió, pero falleció.

Falsos Negativos (FN): El modelo predijo que falleció, pero sobrevivió.

Pregunta de reflexión: En una emergencia, ¿qué error consideran más grave: un FP o un FN? ¿Por qué?

Análisis: Según su matriz, ¿qué tipo de error cometió más el modelo?



Respuesta:

Falsos Positivos (FP): 55 casos

El modelo predijo que el pasajero sobrevivió, pero en realidad no sobrevivió.

Falsos Negativos (FN): 91 casos

El modelo predijo que el pasajero no sobrevivió, pero en realidad sí sobrevivió.

Por lo tanto, el modelo cometió más falsos negativos que falsos positivos.

Reflexión,

En una situación de emergencia, el error más grave podría considerarse el falso positivo, ya que el modelo estaría prediciendo que una persona va a sobrevivir cuando en realidad no lo hace. Esto podría generar una falsa sensación de seguridad y llevar a no priorizar ayuda para alguien que realmente estaba en riesgo.

PASO 7:

Identifiquen a un pasajero que el modelo no haya logrado predecir correctamente.

Miren su clase, sexo y edad. ¿Qué creen que pudo haber confundido al árbol en ese caso particular?

Predictions - Orange													
Show probabilities for		Classes in data		Show classification errors									
Tree	error	Survived	Name	Ticket	Cabin	Passengerid	Pclass	Sex	SibSp	Parch	Fare	Embarked	Age
1	1.00 : 0.00 → 0	1.000	Barah, Mr. Han...	2663	?	763	3	male	0	0	7.2292	C	20
2	0.00 : 1.00 → 1	0.000	Harper, Mr. He...	PC 17572	D33	646	1	male	1	0	76.7292	C	48
3	0.00 : 1.00 → 1	0.000	Hamalainen, M...	250649	?	756	2	male	1	1	14.5000	S	0.67
4	0.01 : 0.99 → 1	0.012	Duff Gordon, La...	11755	A16	557	1	female	1	0	39.6000	C	48
5	0.95 : 0.05 → 0	0.050	Svensson, Mr. J...	347060	?	852	3	male	0	0	7.7750	S	74
6	0.01 : 0.99 → 1	0.012	Silvey, Mrs. Will...	13507	E44	578	1	female	1	0	55.9000	S	39
7	0.33 : 0.67 → 1	0.333	Backstrom, Mrs...	3101278	?	86	3	female	3	0	15.8500	S	33
8	1.00 : 0.00 → 0	0.000	Coleridge, Mr. ...	W/C. 14263	?	243	2	male	0	0	10.5000	S	29
9	0.00 : 1.00 → 1	1.000	Thayer, Mr. Joh...	17421	C68	699	1	male	1	1	110.8833	C	49
10	0.94 : 0.06 → 0	0.056	Sage, Master. T...	CA. 2343	?	160	3	male	8	2	69.5500	S	?
11	0.87 : 0.13 → 0	0.133	Kassem, Mr. Far...	2700	?	525	3	male	0	0	7.2292	C	?
12	0.00 : 1.00 → 1	1.000	Holverson, Mr. ...	113789	?	36	1	male	1	0	52.0000	S	42
13	0.01 : 0.99 → 1	0.012	Crosby, Miss. H...	WE/P 5735	B22	541	1	female	0	2	71.0000	S	36
14	1.00 : 0.00 → 0	0.000	Van der hoef, ...	111240	B19	171	1	male	0	0	33.5000	S	61
15	0.00 : 1.00 → 1	1.000	Hegarty, Miss. ...	365226	?	655	3	female	0	0	6.7500	Q	18
16	1.00 : 0.00 → 0	0.000	Eklund, Mr. Han...	347074	?	765	3	male	0	0	7.7750	S	16
17	1.00 : 0.00 → 0	0.000	Carlsson, Mr. A...	350042	?	757	3	male	0	0	7.7958	S	28
18	0.60 : 0.40 → 0	0.596	Marechal, Mr. P...	11774	C47	840	1	male	0	0	29.7000	C	?
19	0.87 : 0.13 → 0	0.133	Shorney, Mr. Ch...	374910	?	96	3	male	0	0	8.0500	S	?
20	0.87 : 0.13 → 0	0.133	Simmons, Mr. J...	SOTON/OQ 39...	?	564	3	male	0	0	8.0500	S	?
21	0.40 : 0.60 → 1	0.600	Zabour, Miss. T...	2665	?	241	3	female	1	0	14.4542	C	?
22	0.00 : 1.00 → 1	1.000	Rush, Mr. Alfre...	A/4. 20589	?	575	3	male	0	0	8.0500	S	16
23	1.00 : 0.00 → 0	1.000	Dick, Mr. Albert...	17474	B20	691	1	male	1	0	57.0000	S	31
24	0.50 : 0.50 → 0	0.500	Anderson, Mr. ...	19952	E12	461	1	male	0	0	26.5500	S	48
25	1.00 : 0.00 → 0	1.000	Leeni, Mr. Fahli...	2620	?	554	3	male	0	0	7.2250	C	22
26	0.01 : 0.99 → 1	0.012	Dick, Mrs. Alber...	17474	B20	782	1	female	1	0	57.0000	S	17
27	0.33 : 0.67 → 1	0.667	Backstrom, Mr. ...	3101278	?	207	3	male	1	0	15.8500	S	32
28	1.00 : 0.00 → 0	0.000	Gustafsson, Mr...	3101277	?	393	3	male	2	0	7.9250	S	28
29	0.95 : 0.05 → 0	0.050	McKane, Mr. Pe...	28403	?	398	2	male	0	0	26.0000	S	46
30	1.00 : 0.00 → 0	0.000	Bailey, Mr. Perc...	29108	?	758	2	male	0	0	11.5000	S	18
Show performance scores													
		Target class: (Average over classes)											
Model	AUC	CA	F1	Prec	Recall	MCC							
Tree	0.751	0.764	0.765	0.766	0.764	0.484							

Respuestas:

Un pasajero que el modelo no logró predecir correctamente fue Barah, Mr. Han, un hombre de 20 años que viajaba en tercera clase. El modelo predijo que no sobrevivió, pero en realidad sí sobrevivió, por lo que se trata de un falso negativo.

Es posible que el árbol se haya confundido porque combinó características asociadas a baja supervivencia, como ser hombre. Este caso muestra que existen excepciones que el modelo no pudo captar correctamente.