

TRABAJO PRÁCTICO BIG DATA

GRUPO 10: HAY DATA

ETAPAS 1 Y 2

Selección del dataset

Nombre: Retraso_Logística

Filas del dataset: 10.000

Columnas del dataset: 16

Variable Target (la que queremos predecir): **entrega_demorada**

Envíos demorados tiene valores binarios 0,1 siendo 0=No demorado y 1=Demorado. Los envíos demorados representan el 20%.

Definición del problema

Problema:

Un marketplace líder necesita predecir, desde el momento en que el paquete sale del almacén, qué envíos tienen mayor riesgo de sufrir una demora. El objetivo es gestionar la expectativa del cliente de forma proactiva, avisando con anticipación y ofreciendo una compensación si corresponde.

¿Quién usa el modelo?

El modelo lo usarían las áreas de Logística, Customer Experience y/o Operaciones para identificar envíos con riesgo de demora y activar acciones preventivas, como enviar un mensaje por WhatsApp o un cupón de descuento antes de que el cliente se queje.

¿Cuál es el error más costoso?

Falso negativo: predecir que el envío llegará a tiempo cuando en realidad estará demorado.

Este es el error más costoso porque el cliente no recibe ningún aviso previo, no se gestiona su expectativa y probablemente termine con una mala experiencia, reclamo o pérdida de confianza en la plataforma.

Falso positivo: predecir que el envío estará demorado cuando en realidad llega a tiempo.

Este error tiene un costo menor, porque puede implicar enviar un aviso o cupón innecesario, pero no genera una mala experiencia grave. Incluso puede ser percibido como una acción preventiva positiva por parte del cliente.

Conclusión:

En este caso conviene priorizar el Recall de la clase “demorado”
`entrega_demorada = 1`, porque el objetivo principal es detectar la mayor cantidad posible de entregas que realmente van a demorarse. Es preferible aceptar algunos falsos positivos antes que dejar pasar entregas demoradas sin anticipación.


Análisis exploratorio de datos (EDA)

ETAPA 3

En esta etapa la idea principal es revisar los tipos y roles de las variables en Orange. La variable **entrega_demorada** fue definida como target, ya que representa el resultado que se busca predecir: si el envío llegó a tiempo o sufrió una demora.

Las variables **id_pedido**, **codigo_postal_dest** y **valor_declarado_ars** fueron conservadas como variables meta y no utilizadas como predictores del modelo. En el caso de **id_pedido**, se trata de un identificador único sin valor explicativo sobre la demora. En cuanto a **codigo_postal_dest** y **valor_declarado_ars**, si bien presentan problemas de calidad que podrían corregirse mediante transformación de datos, se decidió no incorporarlas al modelado porque su aporte predictivo esperado es bajo o redundante frente a variables más directamente relacionadas con la logística, como **provincia_destino**, **distancia_km**, **proveedor_logistico**, **tipo_envio**, **clima_despacho**, **es_vispera_feriado** e **intentos_previos**.


ANALISIS VARIABLE TARGET




La variable target **entrega_demorada** presenta una distribución desbalanceada. Aproximadamente el 80% de los envíos corresponden a entregas a tiempo 0, mientras que cerca del 20% corresponden a entregas demoradas 1. Esto coincide con la descripción del dataset. Para el negocio, este desbalance es importante porque un modelo podría obtener buenos resultados generales prediciendo mayormente entregas a tiempo, pero fallar en detectar las demoras. Por eso, en la etapa de evaluación será importante mirar especialmente el **Recall de la clase 1 = demorado**.

ANALISIS VARIABLES CATEGÓRICAS:

CLIMA:






Analizando la variable **clima_despacho** mediante un **Mosaic Display**, se observa que la mayoría de los envíos fueron despachados en días despejados, mientras que los casos de tormenta son menos frecuentes. Sin embargo, la categoría “Tormenta” presenta una proporción mucho mayor de entregas demoradas en comparación con “Despejado” y “Lluvia”.

Este hallazgo indica que el clima extremo puede ser una variable relevante para predecir retrasos logísticos. En particular, los envíos despachados en días de tormenta muestran mayor riesgo de demora, lo cual tiene sentido desde el punto de vista operativo porque las tormentas pueden afectar rutas, tiempos de traslado y capacidad de distribución.

Por lo tanto, **clima_despacho** debería considerarse una variable potencialmente predictiva, especialmente por la categoría “Tormenta”.


PROVEEDORES:



La variable **proveedor_logistico** mediante **Mosaic Display**, se observa que los distintos proveedores presentan proporciones de demora relativamente similares. La participación de entregas demoradas se mantiene cercana al promedio general del dataset, sin diferencias visuales muy marcadas entre Andreani, Correo Argentino, Oca y Transporte Propio.

Esto sugiere que, en esta primera exploración, el proveedor logístico no parece ser la variable categórica con mayor poder explicativo sobre las demoras. Sin embargo, se mantiene como una variable relevante desde el punto de vista operativo, ya que pequeñas diferencias de desempeño entre proveedores podrían impactar en la gestión logística.


ES VISPERA DE FERIADO:



Al analizar la variable **es_vispera_feriado** mediante **Mosaic Display**, se observa que la mayoría de los envíos no fueron despachados en víspera de feriado. Sin embargo, dentro de los casos en los que el despacho sí ocurrió en víspera de feriado, la proporción de entregas demoradas aumenta de forma considerable.

Este hallazgo sugiere que la víspera de feriado puede ser un factor relevante para predecir retrasos logísticos. Desde una perspectiva operativa, esto puede explicarse por menor disponibilidad de transporte, reducción de horarios, acumulación de pedidos o interrupciones en la distribución. Por lo tanto, **es_vispera_feriado** se considera una variable potencialmente predictiva del target **entrega_demorada**.


ETIQUETA FRAGIL:



Teniendo en cuenta la variable **etiqueta_fragil**, se observa que tanto los paquetes frágiles como los no frágiles presentan proporciones muy similares de entregas demoradas, cercanas al 20%. Esto indica que, en este dataset, la necesidad de manipulación especial no parece estar asociada a un mayor riesgo de demora.

Si bien desde el punto de vista logístico podría esperarse que los paquetes frágiles requieran mayor cuidado y eventualmente más tiempo de procesamiento, los datos exploratorios no muestran una diferencia relevante entre ambas categorías. Por lo tanto, **etiqueta_fragil** no se considera una de las variables más fuertes para explicar la demora.

CATEGORÍA DEL PRODUCTO:




Esto sugiere que la categoría del producto no parece ser una variable muy predictiva por sí sola.

Podríamos haber esperado que categorías como Muebles tuvieran más demoras por ser productos más voluminosos o difíciles de transportar, pero el gráfico no muestra una diferencia clara respecto del resto.

Esto puede deberse a que el efecto del producto está mejor representado por otras variables más directas.

Al menos en este gráfico, **categoria_producto** no muestra una relación fuerte con **entrega_demorada**.


PROVINCIA DESTINO:



Se puede observar que la variable **provincia_destino** mediante **Mosaic Display**, se observa que las distintas provincias presentan proporciones relativamente similares de entregas demoradas. No se identifican diferencias visuales muy marcadas entre Buenos Aires, CABA, Córdoba, Mendoza, Neuquén, Salta, Santa Fe y Tucumán.

Esto sugiere que, en esta etapa exploratoria, la provincia de destino no parece ser una de las variables con mayor capacidad explicativa sobre la demora. Sin embargo, sigue siendo una variable geográfica relevante, ya que puede estar asociada indirectamente a otros factores como la distancia, la cobertura logística o la disponibilidad de transporte. En este caso, su efecto parece estar mejor representado por una variable más directa como **distancia_km**.


TIPO DE ENVÍO:



Tipo_envio no parece ser una variable muy predictiva por sí sola, porque las proporciones de demora son muy parecidas entre los tres tipos de envío. Entendemos que otras variables categóricas explicarían mejor las demoras en principio.

ANALISIS DE VARIABLES NUMÉRICAS:

DISTANCIA EN KM:




Al analizar la variable **distancia_km**, se observa una relación clara con la variable target **entrega_demorada**. En el gráfico de distribución con probabilidades, la proporción de entregas demoradas aumenta a partir de distancias cercanas a los 1.000 km. Esto indica que los envíos de mayor recorrido presentan mayor riesgo de demora.

El Box Plot refuerza este hallazgo: las entregas demoradas presentan una distancia promedio de aproximadamente 1462 km, mientras que las entregas a tiempo tienen un promedio de aproximadamente 1201 km. Además, la mediana de distancia también es mayor en los casos demorados. Desde una perspectiva logística, esto tiene sentido porque los envíos más largos suelen requerir más etapas de transporte y coordinación, aumentando la exposición a imprevistos.


Por lo tanto, **distancia_km** se considera una variable potencialmente relevante para predecir retrasos logísticos.

PESO DE LOS PAGUETES EN KG:




Al comparar **peso_paquete_kg** según el target **entrega_demorada**, se observa que los envíos a tiempo y los envíos demorados presentan distribuciones prácticamente iguales. Los promedios de ambos grupos son muy similares, cercanos a los 25 kg, y las cajas del **Box Plot** se superponen casi por completo. Además, el valor p elevado indica que no hay una diferencia estadísticamente significativa entre ambos grupos. Por lo tanto, el peso del paquete no parece ser una variable relevante para explicar las demoras en este dataset.

VOLUMEN DEL PAQUETE EN CM3:




En el caso de **volumen_paquete_cm3**, el **Box Plot** muestra distribuciones muy similares entre entregas a tiempo y entregas demoradas. Aunque el promedio y la mediana del grupo demorado son levemente superiores, la diferencia es pequeña y las cajas se superponen ampliamente. Por este motivo, el volumen del paquete no parece explicar de manera relevante la demora en esta primera exploración.

INTENTOS PREVIOS:



Como es observable, la variable **intentos_previos** analizada mediante **Box Plot**, la cantidad de intentos fallidos es muy similar entre los envíos entregados a tiempo y los envíos demorados. Los promedios de ambos grupos son prácticamente iguales, alrededor de 1,5 intentos, y las distribuciones se superponen ampliamente.

Si bien desde el punto de vista operativo podría esperarse que una mayor cantidad de intentos previos esté asociada a demoras, los datos no muestran una diferencia relevante en esta variable. Por lo tanto, **intentos_previos** no parece ser una de las variables numéricas más explicativas en esta etapa del análisis exploratorio.



Además, se utilizó un **Scatter Plot** para analizar la relación entre **distancia_km** e **intentos_previos**, coloreando los puntos según **entrega_demorada**. El gráfico muestra que los casos demorados aparecen distribuidos en todos los niveles de intentos previos, sin una concentración clara en valores más altos. Esto coincide con el **Box Plot**, donde **intentos_previos** no mostró diferencias relevantes entre entregas a tiempo y demoradas. Por lo tanto, esta variable no parece aportar una separación clara del target en esta etapa exploratoria.

Etapas finales EDA con HIPOTESIS:

Concluyendo el EDA con hipótesis de las variables, tanto categóricas como numéricas, más relevantes e influyentes con la información presentada hasta el momento.

Variables relevantes:

- Distancia del envío en KM
- Clima de despacho
- Vísperas de feriado

H1 - Distancia del envío

Los envíos con mayor distancia km tienen mayor probabilidad de sufrir una demora.

Evidencia del EDA:

En el Box Plot, los envíos demorados presentan una distancia promedio y mediana mayor que los envíos entregados a tiempo. Además, en la distribución con probabilidades se observa que, a partir de distancias cercanas a los 1.000 km, aumenta la proporción de casos con entrega_demorada = 1.

Interpretación de negocio:

A mayor distancia entre el almacén y el destino, el envío suele requerir más etapas logísticas, mayor coordinación y más exposición a imprevistos. Por eso, distancia_km parece ser una de las variables más relevantes para anticipar retrasos.

H2 — Clima de despacho

Los envíos despachados en días de **tormenta** tienen mayor probabilidad de demorarse que los enviados con clima despejado o lluvia.

Evidencia del EDA:

En el análisis de clima_despacho, la categoría **Tormenta** muestra una proporción de entregas demoradas claramente superior. Mientras que en “Despejado” y “Lluvia” la demora se mantiene cerca del promedio general, en “Tormenta” la proporción de casos demorados aumenta de forma importante.

Interpretación de negocio:

Las tormentas pueden afectar rutas, tiempos de traslado, disponibilidad de transporte y operaciones de carga o entrega. Por eso, esta variable aporta información útil para detectar envíos con mayor riesgo y activar avisos preventivos al cliente.

H3 — Víspera de feriado

Los envíos despachados en víspera de feriado tienen mayor probabilidad de presentar demora.

Evidencia del EDA:

En el Mosaic Display de es_vispera_feriado, los casos con valor **Sí** muestran una proporción de demoras más alta que los casos con valor **No**. Aunque hay menos envíos en víspera de feriado, dentro de ese grupo la presencia de entregas demoradas es considerablemente mayor.

Interpretación de negocio:

En vísperas de feriado puede haber menor capacidad operativa, acumulación de pedidos, reducción de horarios o menor disponibilidad de transportistas. Esto puede aumentar el riesgo de incumplir la promesa de entrega.

Aclaración final de la etapa del EDA:

Entendemos que este análisis e hipótesis no implican causalidad definitiva, pero nos ayudan a dar un panorama más amplio respecto a la etapa siguiente del proyecto.

Preprocesamiento y Selección de variables

ETAPA 4

Antes de avanzar con la etapa de modelado, se debe realizar un proceso de preprocesamiento de datos con el objetivo de preparar el dataset para su correcta utilización en Orange. Esta etapa resulta fundamental porque permite detectar posibles problemas de calidad en la información, como valores faltantes, datos inconsistentes, variables irrelevantes o registros que puedan afectar el desempeño del modelo predictivo.

Para empezar, se verificó la presencia de valores faltantes (**NULOS**) mediante el widget Column Statistics.



En las variables analizadas no se observaron valores nulos, ya que todas presentaron 0% de datos faltantes. Por este motivo, no fue necesario aplicar imputación mediante el widget Impute.

Usando las mismas capturas analizamos los **valores extremos o posibles outliers**


Aparecen mínimos y máximos:

- peso_paquete_kg: va de **0.11kg a 50 kg**.
- volumen_paquete: va de **526 a 99.996**.
- distancia_km: va de **10km a 2.499 km**.
- intentos_previos: va de **0 a 3**.

A simple vista, no parecen valores imposibles. Son rangos amplios, pero tienen sentido para logística. Por ejemplo, un envío de casi 2.500 km puede ser real si hay envíos interprovinciales.


Decidimos incorporar uso de box plots para complementar el análisis:

Variable: volumen_paquete_cm3




La mediana ronda los **50.866 cm3**. Aunque hay paquetes de distinto tamaño, los valores parecen posibles dentro de una operación logística. No se detectan valores absurdos, como volúmenes negativos o extremadamente desproporcionados.

Variable: peso_paquete_kg




La mediana está alrededor de **25,35 kg** y los valores se distribuyen entre paquetes livianos y paquetes pesados. No se observan valores imposibles, ya que el rango puede ser razonable para envíos de e-commerce con distintos tipos de productos.

Variable: distancia_km



La mediana está cerca de **1.258 km**, con valores que llegan aproximadamente hasta **2.500 km**. Si bien son distancias altas, tienen sentido en un esquema de envíos interprovinciales. Por eso no se consideran errores, sino casos reales del negocio.


Variable: intentos_previos



Toma valores entre **0 y 3**, lo cual es totalmente lógico porque representa visitas fallidas anteriores al domicilio. No presenta valores negativos ni cantidades imposibles.

En todos los casos se observaron rangos amplios, pero coherentes con el contexto logístico del problema. A partir de esta revisión, se decidió no eliminar ni modificar registros por outliers, ya que no se detectaron valores imposibles como números negativos, distancias incoherentes o cantidades fuera de escala. En lugar de tratarlos como errores, los valores extremos fueron conservados porque pueden representar situaciones reales de la operación logística y aportar información útil para predecir posibles demoras.



Eliminación de variables para el modelo:







Como mencionamos al inicio del EDA, la variable **id_pedido** fue excluida del conjunto de variables predictoras, ya que funciona únicamente como identificador del envío. Al no representar una característica operativa del pedido, no aporta información útil para predecir el retraso y podría introducir ruido en el modelo.


Cabe aclarar también que la variable **fecha_despacho** fue conservada como variable meta y no utilizada como predictor del modelo. Esta decisión se tomó porque, en su formato original, la fecha cruda no aporta una interpretación directa sobre la probabilidad de demora. Su valor analítico podría aumentar si se transformara en variables derivadas, como día de la semana o mes de despacho, pero en esta instancia se priorizaron variables logísticas más directamente explicativas, como **distancia_km**, **proveedor_logistico**, **tipo_envio**, **clima_despacho**, **es_vispera_feriado** e **intentos_previos**.

Como próximo paso se analizaron las **inconsistencias en los formatos de las variables categóricas** mediante el uso del widget Distributions:










Lectura de las variables categóricas

- **provincia_destino:** aparecen categorías claras como Buenos Aires, CABA, Córdoba, Mendoza, Neuquén, Salta, Santa Fe y Tucumán. No se ven provincias repetidas por errores de escritura.
- **categoria_producto:** aparecen Bazar, Electrónica, Indumentaria, Juguetes y Muebles. Las categorías están limpias.
- **proveedor_logistico:** aparecen Andreani, Correo Argentino, Oca y Transporte Propio. No hay duplicados aparentes.
- **clima_despacho:** aparecen Despejado, Lluvia y Tormenta. Parece Correcto.
- **es_vispera_feriado:** aparecen No y Sí. No hay errores aparentes.
- **tipo_envio:** aparecen Express, Normal y Same-Day. Sin duplicados.
- **etiqueta_fragil:** aparecen No y Sí. Correcto.

No se detectaron inconsistencias visibles de formato en las variables categóricas. Por lo tanto, no fue necesario realizar transformaciones de unificación. Las variables fueron conservadas en su formato original.

Feature engineering (creación de nueva variable):

Como último paso del proceso de preprocesamiento, se utilizó el widget **Formula** de Orange para crear una nueva variable denominada `indice_carga_distancia`. Esta variable surge de multiplicar `distancia_km` por `peso_paquete_kg`, con el objetivo de representar de manera combinada la carga logística del envío.



Data Table (1) - Orange

Info
10000 instances (no missing data)
13 features
Target with 2 values
3 meta attributes

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
Clear Selection
☒ Select full rows

Restore Original Order
Send Automatically

	id	provincia_destino	categoria_producto	peso_paquete_kg	valor_moneda_paquete_c	proveedor_logistico	distancia_km	clima_despacho	s_visperra_feriado	tipo_envio	intentos_previos	etiqueta_fragil	tiempo_carga_distancia
1	12-06	Santa Fe	Electrónica	32.80	34653.0	Transporte Pro...	294	Despejado	No	Express	1	No	9643.2
2	12-09	Santa Fe	Indumentaria	40.29	87819.0	Correo Argentino	1652	Despejado	No	Same-Day	0	Si	66559.1
3	06-01	Córdoba	Electrónica	5.27	5777.0	Andreani	1386	Despejado	No	Same-Day	2	No	7304.22
4	04-20	Buenos Aires	Bazar	23.76	90518.0	Correo Argentino	555	Despejado	No	Express	0	No	13186.8
5	05-03	Neuquén	Electrónica	20.81	58605.0	Andreani	150	Tormenta	No	Express	2	Si	3121.5
6	10-29	Córdoba	Indumentaria	44.40	19673.0	Transporte Pro...	2428	Lluvia	No	Express	3	Si	10780.3
7	04-24	Córdoba	Bazar	27.90	12709.0	Correo Argentino	1232	Despejado	No	Express	1	No	34372.8
8	09-05	Córdoba	Bazar	49.84	34277.0	Oca	1010	Despejado	No	Express	2	No	50338.4
9	04-12	CABA	Muebles	37.64	78607.0	Transporte Pro...	224	Lluvia	No	Express	3	No	8431.36
10	09-22	Tucumán	Indumentaria	6.83	51974.0	Andreani	1574	Despejado	No	Express	0	Si	10750.4
11	08-03	Neuquén	Muebles	31.13	99369.0	Andreani	1735	Despejado	Si	Normal	3	No	54010.5
12	01-08	Salta	Electrónica	35.60	26325.0	Correo Argentino	2241	Tormenta	No	Normal	3	No	79779.6
13	05-03	Tucumán	Juguetes	42.41	16032.0	Andreani	2041	Tormenta	No	Same-Day	2	Si	86558.8
14	05-26	Mendoza	Juguetes	35.73	90124.0	Correo Argentino	1134	Despejado	No	Express	1	Si	40517.8
15	02-16	Mendoza	Bazar	41.59	20153.0	Transporte Pro...	622	Lluvia	Si	Express	2	No	25869
16	12-10	Neuquén	Juguetes	4.52	75540.0	Transporte Pro...	1112	Despejado	No	Express	0	Si	5026.24
17	05-14	Mendoza	Juguetes	47.58	55731.0	Transporte Pro...	1112	Despejado	No	Same-Day	2	Si	52909
18	09-15	Córdoba	Bazar	25.27	8071.0	Transporte Pro...	1724	Despejado	Si	Same-Day	1	Si	43565.5
19	12-21	Córdoba	Bazar	12.99	44192.0	Andreani	836	Lluvia	No	Normal	0	Si	10859.6
20	08-01	Mendoza	Muebles	6.67	34530.0	Andreani	1609	Despejado	No	Normal	3	Si	10732
21	06-07	Neuquén	Indumentaria	49.15	80074.0	Correo Argentino	2130	Despejado	Si	Normal	1	No	104690
22	04-23	Córdoba	Indumentaria	45.71	61585.0	Transporte Pro...	1145	Lluvia	No	Express	2	No	52338
23	08-06	Mendoza	Juguetes	9.65	35794.0	Transporte Pro...	1663	Despejado	Si	Express	2	No	16048
24	02-02	Neuquén	Muebles	6.17	69266.0	Oca	1911	Lluvia	No	Same-Day	3	No	11790.9
25	06-20	Salta	Muebles	3.31	4914.0	Andreani	1329	Despejado	No	Express	1	Si	4398.99
26	04-19	CABA	Muebles	0.79	4146.0	Transporte Pro...	1928	Despejado	No	Express	3	No	1523.12
27	11-08	Neuquén	Juguetes	21.68	24639.0	Oca	2423	Despejado	No	Same-Day	0	No	52530.6
28	01-19	CABA	Indumentaria	18.09	28537.0	Correo Argentino	1343	Despejado	No	Same-Day	1	Si	24294.9
29	06-30	Salta	Indumentaria	38.82	55842.0	Correo Argentino	2138	Tormenta	No	Same-Day	3	Si	82997.2
30	02-02	Córdoba	Indumentaria	47.83	27649.0	Transporte Pro...	132	Lluvia	No	Express	2	No	6313.56
31	06-25	Neuquén	Muebles	25.10	98895.0	Andreani	669	Lluvia	Si	Normal	0	Si	16791.9
32	12-04	Mendoza	Muebles	41.29	18494.0	Andreani	498	Lluvia	No	Normal	2	Si	20562.4
33	01-01	Tucumán	Juguetes	37.23	67863.0	Transporte Pro...	737	Despejado	No	Normal	2	Si	27438.5
34	11-05	Neuquén	Juguetes	29.71	35888.0	Correo Argentino	50	Despejado	No	Same-Day	1	Si	1485.5

La lógica detrás de esta transformación es que un paquete pesado no implica la misma complejidad si recorre una distancia corta que si debe trasladarse muchos kilómetros. Por eso, al combinar peso y distancia, la nueva variable permite capturar una dimensión más completa del esfuerzo logístico asociado a cada envío. Esta variable fue incorporada como predictora para evaluar si aporta información adicional al modelo de clasificación de entregas demoradas.

Conclusión de la etapa de preprocesamiento:

El preprocesamiento permitió validar la calidad del dataset, excluir variables no adecuadas para el modelado y construir una nueva variable derivada con sentido operativo. A partir de estas decisiones, el dataset quedó preparado para avanzar hacia la etapa de modelado predictivo con variables más limpias, relevantes e interpretables para el problema de negocio.


MODELADO Y EVALUACIÓN

ETAPA 5 Y 6

Para la etapa de modelado se trabajó con el dataset ya preprocesado, luego de la limpieza de datos, la selección de variables relevantes y la construcción de la variable derivada **indice_carga_distancia**. Como ya sabemos la variable objetivo utilizada fue **entrega_demorada**, que clasifica los envíos en dos categorías: entregas a tiempo y entregas demoradas.

Una vez creada la nueva variable, se utilizó la función/comando Continuize para transformar las variables categóricas en numéricas (binarias) para que los modelos las puedan leer correctamente.

Con el objetivo de evaluar la capacidad predictiva de distintos enfoques, se dividió el dataset en dos subconjuntos: un **80% de los datos para entrenamiento** y un **20% para testeo**. Esta separación permite entrenar los modelos sobre una parte de la información y luego evaluar su desempeño sobre datos no utilizados durante el entrenamiento.



Como se puede observar, se compararon tres modelos de clasificación supervisada:

Modelo	Rol en el análisis
• Regresión Logística:	Modelo base e interpretable. Permite tener una referencia inicial y comprender relaciones generales entre variables.
• Random Forest:	Modelo de mayor complejidad, capaz de captar relaciones no lineales e interacciones entre variables.
• Naive Bayes:	Tercer modelo elegido, de enfoque probabilístico, simple y rápido de entrenar.

Los modelos fueron evaluados inicialmente en el conjunto/tabla de Entrenamiento mediante el widget **Test and Score**, utilizando validación cruzada con 10 repeticiones y estratificación activada. Luego, se aplicaron sobre el conjunto/tabla de Test mediante el widget **Predictions**, para observar su desempeño sobre datos no vistos previamente.

Hiperparámetros usados en cada modelo:

Logistic Regression - Orange X

Name
Logistic Regression

Regularization type: Ridge (L2) v

Strength:
Weak Strong
C=1

☐ Balance class distribution

☒ Apply Automatically

≡ ? | 9000 | 9 |

Random Forest - Orange X

Name
Random Forest

Basic Properties

Number of trees: 10

☐ Number of attributes considered at each split: 5

☐ Replicable training

☐ Balance class distribution


Growth Control

☐ Limit depth of individual trees: 3

☒ Do not split subsets smaller than: 3

☒ Apply Automatically

≡ ? | 9000 | - |



Aclaración: Naive Bayes sin Hiperparámetros aparentes.

Test and Score con target-promedio de las clases:

Test and Score - Orange

☒ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Evaluation results for target: (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.650	0.792	0.747	0.738	0.792	0.140
Logistic Regression	0.704	0.806	0.753	0.760	0.806	0.176
Naive Bayes	0.691	0.798	0.752	0.748	0.798	0.162

Compare models by: Area under ROC curve

☐ Negligible diff.: 0.1


	Random Forest	Logistic Regression	Naive Bayes
Random Forest		0.000	0.002
Logistic Regression	1.000		0.995
Naive Bayes	0.998	0.005	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.


Predictions con target-promedio de las clases:

minoritaria, por lo que resulta necesario analizar específicamente la clase 1, correspondiente a las entregas demoradas.

Test and Score con target-clase 1:



Predictions con target-clase 1:



Análisis:

Al analizar específicamente la clase 1, correspondiente a las entregas demoradas, la interpretación cambia de manera importante. Si bien las métricas promedio mostraban resultados aceptables, las métricas de la clase demorada evidencian que los modelos tienen dificultades para detectar correctamente los casos de demora.

En el conjunto de entrenamiento, Naive Bayes obtuvo el mayor **F1-score** para la clase 1, con 0.211, y el mayor **Recall**, con 0.138. Random Forest presentó un desempeño muy cercano, con un **F1-score** de 0.201 y un **Recall** de 0.133. La Regresión Logística, aunque tuvo el mejor **AUC** y la mayor precisión, obtuvo un **Recall** de 0.117, lo que indica que detecta una proporción baja de las entregas efectivamente demoradas.

En el conjunto de test, Random Forest fue el modelo con mejor **Recall** para la clase demorada, con 0.143, y también el mayor **F1-score**, con 0.218. Naive Bayes quedó muy cerca, con un **F1-score** de 0.215 y un **Recall** de 0.138, además de presentar el **MCC** más alto, con 0.170. La Regresión Logística mantuvo el **AUC** más alto, con 0.705, pero su **Recall** bajó a 0.097, lo que significa que fue el modelo que menos demoras reales logró detectar.

Estos resultados muestran que no hay señales fuertes de overfitting, porque los valores obtenidos en test son similares a los del entrenamiento. El problema principal parece estar más relacionado con un posible **underfitting** respecto de la clase minoritaria, o con la dificultad de los modelos para aprender correctamente los patrones asociados a las entregas demoradas. Esto puede deberse al desbalance del target, ya que la mayoría de los casos corresponden a entregas a tiempo.

Desde el punto de vista del negocio, el error más costoso es el falso negativo: clasificar una entrega como “a tiempo” cuando en realidad se demorará. Este error impide que la empresa pueda anticiparse al cliente, enviar un aviso preventivo o aplicar una compensación. Por eso, para este problema, el Recall y el F1-score de la clase 1 son métricas especialmente relevantes.

En función exclusivamente de estos resultados, Random Forest aparece como el modelo más conveniente para detectar demoras, ya que obtiene el mayor Recall y F1-score en el conjunto de test para la clase 1. Sin embargo, Naive Bayes también presenta un desempeño competitivo y un MCC superior. La Regresión Logística, aunque es interpretable y presenta buen AUC general, resulta menos adecuada si el objetivo principal es detectar la mayor cantidad posible de entregas demoradas.

ETAPA DE PRUEBAS

Creemos que los resultados no fueron los que esperábamos entonces se realizaron diferentes pruebas para testear la posibilidad de aumentar dichos resultados.


Prueba 1

Nueva variable derivada dia_semana_despacho:

En la versión 2.0 del pipeline se incorporó la variable **dia_semana_despacho**, derivada de **fecha_despacho**, con el objetivo de evaluar si el día de salida del paquete aportaba información predictiva sobre la demora. La fecha original se mantuvo como meta, mientras que el día de semana fue incluido como feature categórica.

Resultados:

Test and score:



Predictions:

Predictions - Orange

Show classification errors

	Random Forest	error	Logistic Regression	error	Naive Bayes	error
1	0.95 : 0.05 → 0	0.050	0.87 : 0.13 → 0	0.130	0.92 : 0.08 → 0	0.076
2	0.70 : 0.30 → 0	0.299	0.85 : 0.15 → 0	0.152	0.74 : 0.26 → 0	0.261
3	0.96 : 0.04 → 0	0.045	0.90 : 0.10 → 0	0.096	0.93 : 0.07 → 0	0.074
4	0.73 : 0.27 → 0	0.273	0.86 : 0.14 → 0	0.143	0.84 : 0.16 → 0	0.161
5	0.83 : 0.17 → 0	0.170	0.88 : 0.12 → 0	0.124	0.90 : 0.10 → 0	0.104
6	0.83 : 0.17 → 0	0.833	0.78 : 0.22 → 0	0.779	0.74 : 0.26 → 0	0.744
7	1.00 : 0.00 → 0	0.000	0.91 : 0.09 → 0	0.086	0.92 : 0.08 → 0	0.078
8	1.00 : 0.00 → 0	0.000	0.92 : 0.08 → 0	0.078	0.93 : 0.07 → 0	0.070
9	0.73 : 0.27 → 0	0.267	0.79 : 0.21 → 0	0.211	0.80 : 0.20 → 0	0.196
10	0.92 : 0.08 → 0	0.080	0.83 : 0.17 → 0	0.169	0.75 : 0.25 → 0	0.250
11	0.57 : 0.43 → 0	0.435	0.47 : 0.53 → 1	0.529	0.53 : 0.47 → 0	0.471
12	0.83 : 0.17 → 0	0.167	0.87 : 0.13 → 0	0.130	0.86 : 0.14 → 0	0.141
13	0.61 : 0.39 → 0	0.610	0.54 : 0.46 → 0	0.538	0.66 : 0.34 → 0	0.657
14	0.28 : 0.72 → 1	0.275	0.36 : 0.64 → 1	0.362	0.37 : 0.63 → 1	0.368
15	0.85 : 0.15 → 0	0.150	0.79 : 0.21 → 0	0.213	0.81 : 0.19 → 0	0.190
16	0.76 : 0.24 → 0	0.245	0.91 : 0.09 → 0	0.089	0.94 : 0.06 → 0	0.055
17	0.88 : 0.12 → 0	0.125	0.83 : 0.17 → 0	0.172	0.74 : 0.26 → 0	0.261
18	0.70 : 0.30 → 0	0.700	0.87 : 0.13 → 0	0.865	0.81 : 0.19 → 0	0.815
19	0.90 : 0.10 → 0	0.100	0.89 : 0.11 → 0	0.114	0.89 : 0.11 → 0	0.114
20	0.58 : 0.42 → 0	0.422	0.53 : 0.47 → 0	0.466	0.44 : 0.56 → 1	0.563
21	0.96 : 0.04 → 0	0.040	0.83 : 0.17 → 0	0.171	0.79 : 0.21 → 0	0.213
22	0.89 : 0.11 → 0	0.115	0.93 : 0.07 → 0	0.067	0.94 : 0.06 → 0	0.058
23	1.00 : 0.00 → 0	0.000	0.90 : 0.10 → 0	0.100	0.92 : 0.08 → 0	0.084
24	1.00 : 0.00 → 0	0.000	0.91 : 0.09 → 0	0.087	0.94 : 0.06 → 0	0.060
25	0.90 : 0.10 → 0	0.100	0.88 : 0.12 → 0	0.123	0.91 : 0.09 → 0	0.092
26	0.90 : 0.10 → 0	0.100	0.92 : 0.08 → 0	0.083	0.93 : 0.07 → 0	0.066
27	0.90 : 0.10 → 0	0.100	0.90 : 0.10 → 0	0.099	0.93 : 0.07 → 0	0.071
28	1.00 : 0.00 → 0	0.000	0.92 : 0.08 → 0	0.078	0.95 : 0.05 → 0	0.049

Show performance scores

Target class: 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.673	0.790	0.189	0.462	0.119	0.150
Logistic Regression	0.703	0.796	0.178	0.530	0.107	0.167
Naive Bayes	0.686	0.792	0.200	0.486	0.126	0.165

entrega_demora	id_pedido	fecha_despacho	codigo_postal_des	valor_declarado_ars	semana_despacho	provincia_destino	categoria_producto	peso_paquete_kg	valor_paquete_ars	row
0	400	8/11/2023	B2498AAA	111135	miércoles	Buenos Aires	Juguetes	1321	416390	Tran
0	7248	5/8/2023	B3874AAA	14385	sábado	CABA	Muebles	3535	837580	Corr
0	6407	6/8/2023	B3746AAA	101696	domingo	Neuquén	Juguetes	2997	336170	Tran
0	883	11/5/2023	B5394AAA	135319	jueves	Buenos Aires	Bazar	3433	361680	Oca
0	3566	23/9/2023	B9054AAA	103392	sábado	Salta	Bazar	61	938760	Corr
1	4286	4/2/2023	B9455AAA	143269	sábado	Tucumán	Juguetes	2369	369410	Corr
0	1180	18/10/2023	B6292AAA	25271	miércoles	Salta	Electrónica	2747	729140	Tran
0	5449	30/5/2023	B3791AAA	11009	martes	Córdoba	Bazar	841	458710	Corr
0	4245	18/6/2023	B1356AAA	95886	domingo	Tucumán	Bazar	705	291410	Tran
0	5219	29/11/2023	B2748AAA	ARS 42438	miércoles	Salta	Muebles	2673	357980	And
0	3977	8/11/2023	B2367AAA	ARS 13658	miércoles	Tucumán	Juguetes	2212	382460	Tran
0	2131	1/1/2024	B7201AAA	94079	lunes	Neuquén	Electrónica	4321	472750	Corr
1	5079	12/11/2023	B6757AAA	27512	domingo	Buenos Aires	Muebles	37	762520	And
0	457	8/2/2023	B5984AAA	ARS 7210	miércoles	Mendoza	Muebles	688	158550	Tran
0	5583	10/2/2023	B9979AAA	48167	viernes	Córdoba	Electrónica	1488	319540	Oca
0	5176	18/8/2023	B9487AAA	57916	viernes	Mendoza	Bazar	1763	51600	And
0	1951	17/4/2023	B8025AAA	542870	lunes	Neuquén	Bazar	4709	966590	And
1	5373	7/6/2023	B6307AAA	143749	miércoles	CABA	Electrónica	3094	531110	Corr
0	690	23/9/2023	B4121AAA	524737	sábado	Mendoza	Muebles	1195	526660	Tran
0	8853	13/10/2023	B8285AAA	5120679	viernes	Salta	Bazar	4299	443350	Corr
0	6526	17/1/2023	B190X	5121174	martes	Neuquén	Juguetes	1365	890340	Oca
0	9822	17/7/2023	B1101AAA	5140399	jueves	Santa Fe	Indumentaria	2586	598940	And
0	6489	25/5/2023	B7379AAA	ARS 115400	jueves	Mendoza	Electrónica	4385	89010	Tran
0	6922	29/7/2023	B8901AAA	597364	sábado	Tucumán	Bazar	1284	487100	And
0	1954	4/2/2023	B9877AAA	ARS 20781	sábado	CABA	Muebles	155	312400	And
0	7635	23/4/2023	B2279AAA	523955	domingo	Córdoba	Bazar	1445	324300	And
0	5637	8/4/2023	B9649AAA	ARS 97845	sábado	Córdoba	Muebles	3251	535430	And
0	7155	10/7/2023	B6827AAA	ARS 43883	lunes	Córdoba	Electrónica	1743	823560	Oca

Los resultados muestran que la nueva variable no produjo una mejora sustancial en la detección de la clase 1. Si bien los modelos mantienen niveles de **Accuracy** cercanos al 79%-80%, el Recall continúa siendo bajo, lo que indica que todavía identifican una proporción limitada de las entregas demoradas reales. Esto confirma que, en un problema con clases desbalanceadas, el Accuracy no alcanza para evaluar correctamente el desempeño del modelo.

En el conjunto de test, Naive Bayes obtuvo el mayor **Recall** para la clase 1, con un valor de 0.126, seguido de Random Forest con 0.119. Sin embargo, ambos valores siguen siendo bajos para el objetivo de negocio, ya que el modelo debería anticipar la mayor cantidad posible de demoras. Por lo tanto, la variable **dia_semana_despacho** puede aportar información adicional, pero no alcanza por sí sola para resolver el problema de detección de retrasos.

Prueba 2

Limpieza de la variable valor declarado ars:

Como segunda prueba de mejora, se decidió limpiar la variable **valor_declarado_ars**, ya que originalmente contenía símbolos de moneda y caracteres de texto mezclados con valores numéricos. A partir de ella se creó la variable **valor_declarado_limpio**, con formato numérico mediante el widget Formula, para que pudiera ser incorporada como feature dentro de los modelos.

Formula - Orange

Variable Definitions

New :=clarado_ars).replace("ARS", "").replace("\$", "").replace(" ", "")

Remove ☐ Meta attribute

N indice_carga_distancia := distancia_km * peso_paquete_kg

N valor_declarado_limpio := float(str(valor_declarado_ars).replace("ARS", "").replace("\$", "").replace(" ", ""))

Resultados:

Test and Score:

Test and Score - Orange

☒ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Evaluation results for target 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.646	0.792	0.181	0.401	0.117	0.127
Logistic Regression	0.660	0.802	0.108	0.471	0.061	0.112
Naive Bayes	0.692	0.799	0.198	0.460	0.126	0.159

Predictions:

☒ Show performance scores Target class: 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.659	0.787	0.190	0.442	0.121	0.143
Logistic Regression	0.704	0.796	0.184	0.529	0.112	0.170
Naive Bayes	0.686	0.792	0.194	0.481	0.121	0.159

El objetivo de esta transformación fue evaluar si el valor económico declarado del paquete aportaba información relevante para anticipar entregas demoradas.


Luego de incorporar esta variable, los resultados no mostraron una mejora sustancial en el **Recall** de la clase 1. En el conjunto de predicciones, Random Forest pasó de un Recall de 0.119 a 0.121 y Logistic Regression de 0.107 a 0.112, mientras que Naive Bayes descendió levemente de 0.126 a 0.121.

Por lo tanto, la limpieza de **valor_declarado_ars** tuvo un aporte predictivo limitado. Esto sugiere que el valor declarado del producto no es, por sí solo, una variable suficientemente explicativa para mejorar la detección de entregas demoradas.

Prueba 3

Nueva variable es_fin_de_semana:

Como tercera prueba de mejora, se creó la variable **es_fin_de_semana**, derivada de **dia_semana_despacho**, con el widget Formula. El objetivo fue simplificar la información temporal y evaluar si la distinción entre días hábiles y fines de semana permitía capturar mejor posibles diferencias operativas en la logística de despacho.



Resultados:

Test and Score:

Test and Score - Orange						
☒ Cross validation Number of folds: 10 ☒ Stratified ☐ Cross validation by feature dia_semana_despaci ☐ Random sampling Repeat train/test: 10 Training set size: 66 % ☒ Stratified ☐ Leave one out ☐ Test on train data ☐ Test on test data						
Evaluation results for target 1						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.650	0.796	0.218	0.439	0.145	0.161
Logistic Regression	0.655	0.803	0.092	0.485	0.051	0.105
Naive Bayes	0.693	0.799	0.197	0.456	0.125	0.156

Predictions:

☒ Show performance scores Target class: 1						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.672	0.794	0.223	0.504	0.143	0.184
Logistic Regression	0.698	0.794	0.116	0.509	0.066	0.124
Naive Bayes	0.688	0.790	0.186	0.462	0.117	0.148

A partir de estos resultados, se observa que Random Forest fue el modelo con mejor desempeño para el objetivo principal del trabajo, ya que obtuvo el mayor **Recall** para la clase 1, con un valor de 0.143. Esto significa que logró identificar una mayor proporción de entregas demoradas reales en comparación con los otros modelos evaluados. Además, también presentó el mejor F1-score y el mejor MCC, lo que refuerza su elección como el modelo más equilibrado para este problema.


Si bien Logistic Regression obtuvo el AUC más alto, su **Recall** fue considerablemente menor, con un valor de 0.066. Esto indica que, aunque el modelo tiene cierta capacidad general para separar clases, no resulta tan útil para el objetivo de negocio, ya que detecta muy pocas entregas demoradas. En cambio, Random Forest logra un mejor equilibrio entre detección de demoras y precisión de las alertas.

De todos modos, el Recall obtenido sigue siendo bajo en términos absolutos. Esto muestra que el modelo todavía tiene dificultades para identificar correctamente la clase minoritaria. Sin embargo, la prueba con **es_fin_de_semana** permitió mejorar parcialmente el desempeño de Random Forest.

Prueba 4


En esta prueba se decidieron realizar diferentes cambios.

En primer lugar, se observó que los días de semana con más envíos demorados, a pesar de que la diferencia sea poca, son domingo y jueves.




Es por esto por lo que, de todas formas, ambos días fueron incluidos como features.

Lo mismo ocurrió con las provincias de destino, Buenos Aires y Córdoba mostraban un pequeño incremento en los envíos demorados por lo que se los incluyo como features.



Exactamente el mismo fue el caso para Proveedor Logístico, donde Transporte propio y Correo Argentino presentaron más envíos fuera de tiempo.



Como último cambio, se ajustaron los Hiperparámetros de los modelos. Específicamente Random Forest y Logistic Regression agregan el parámetro Balance Class Distribution, el cual fue activado. El mismo le indica al modelo que penalice más los errores cometidos sobre la clase minoritaria (demorados), de forma proporcional al desbalance.

Orange advierte: "Weighting by class may decrease performance". Esto se refiere al accuracy general, que efectivamente bajó. Sin embargo, al ser el Recall la métrica prioritaria para el negocio, esta caída en accuracy es aceptada conscientemente a cambio de una mejora significativa en la detección de demoras.

Por otro lado, también se ajustó el número de árboles del Random Forest con el fin de mejorar la estabilidad del modelo. Al tener más árboles, el resultado final depende menos de un árbol individual y se vuelve menos "aleatorio".

Random Forest - Orange

Name

Random Forest

Basic Properties

Number of trees:

100

☐

Number of attributes considered at each split:

5

☐

Replicable training

☒

Balance class distribution

Growth Control

☐

Limit depth of individual trees:

3

☒

Do not split subsets smaller than:

5

☒

Apply Automatically

≡ ? 📄 | ➡ 8000 | - ➡ 📄 📧

⚠️ Weighting by class ma...

Logistic Regression - Orange

Name

Logistic Regression

Regularization type:

Ridge (L2)

Strength:

Weak

Strong

C=1

☒ Balance class distribution

☒ Apply Automatically

Resultados:

Test and Score:

Test and Score - Orange

☒ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Evaluation results for target 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.644	0.714	0.319	0.299	0.341	0.139
Logistic Regression	0.706	0.662	0.405	0.309	0.586	0.219
Naive Bayes	0.697	0.790	0.339	0.443	0.275	0.232

Predictions:

☒ Show performance scores

Target class: 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.637	0.717	0.331	0.322	0.340	0.151
Logistic Regression	0.705	0.656	0.414	0.319	0.590	0.219
Naive Bayes	0.698	0.786	0.348	0.469	0.277	0.242

La mejora más importante se observa en **Logistic Regression**, cuyo Recall alcanzó **0.590**. Esto representa un cambio significativo respecto de la mejor versión anterior, donde el Recall más alto de la clase 1 había sido **0.143** con Random Forest. Es decir, el modelo pasó de detectar una proporción muy baja de entregas demoradas a identificar cerca del **59% de los casos demorados reales**.

Este resultado confirma que la modificación con mayor impacto fue la activación de **Balance class distribution**. Al equilibrar el peso de las clases, el modelo comenzó a prestar mayor atención a la clase minoritaria, lo que permitió mejorar fuertemente el Recall. Sin embargo, esta mejora tuvo un costo: el **Accuracy** de

Logistic Regression bajó a **0.656** y la **Precision** quedó en **0.319**. Esto indica que el modelo detecta muchas más demoras, pero también genera más falsos positivos, es decir, más casos clasificados como demorados, aunque finalmente lleguen a tiempo.

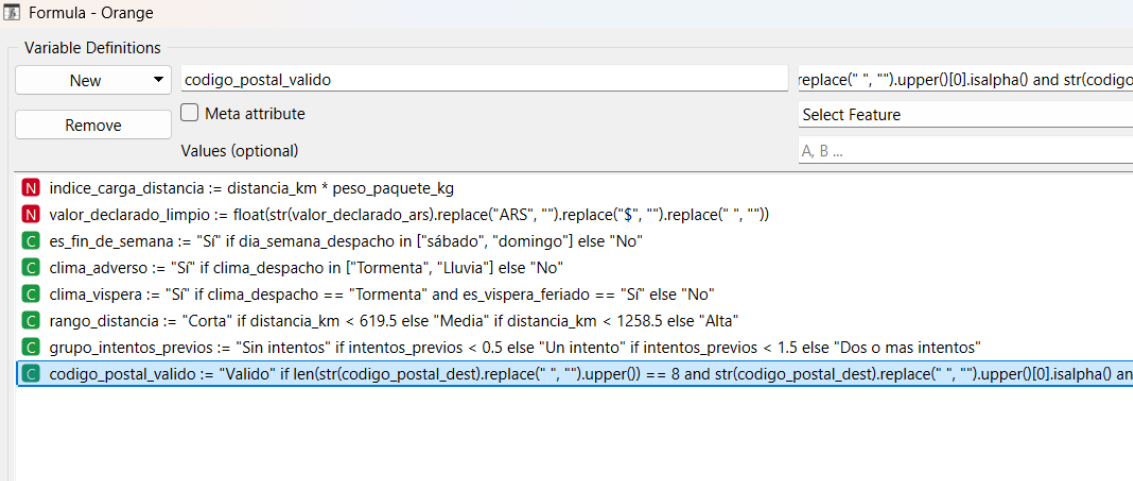
Desde el punto de vista del negocio, este trade-off puede ser aceptable. En este problema, el error más costoso es el falso negativo: predecir que un envío llegará a tiempo cuando en realidad se va a demorar. Ese error impide anticiparse al reclamo del cliente, enviar una notificación preventiva o tomar medidas compensatorias. Por eso, aunque la Precision disminuya, el aumento del Recall resulta valioso si el objetivo principal es detectar la mayor cantidad posible de demoras reales.

En conclusión, esta prueba muestra que el bajo **Recall** no se debía únicamente a la selección inicial de variables, sino también al desbalance de clases. La incorporación de variables seleccionadas a partir del EDA ayudó a refinar el modelo, pero el cambio más determinante fue el ajuste de balanceo de clases. A partir de esta prueba, **Logistic Regression con Balance class distribution activado** se posiciona como el modelo más adecuado si se prioriza la detección de entregas demoradas, ya que logró el mayor **Recall** de la clase 1.

Prueba 5:

Limpieza de la variable `codigo_postal_dest`:

Para esta prueba decidimos trabajar sobre la variable **`codigo_postal_dest`**, ya que presentaba inconsistencias de formato. En lugar de utilizar el código postal original como variable predictiva, se creó una variable derivada llamada **`codigo_postal_valido`**, cuyo objetivo fue identificar si el código postal cargado tenía un formato válido o inválido.




Formula - Orange

Variable Definitions

Variable	Formula
<code>codigo_postal_valido</code>	<code>replace(" ", "").upper()[0].isalpha() and str(codigo</code>
<code>indice_carga_distancia</code>	<code>:= distancia_km * peso_paquete_kg</code>
<code>valor_declarado_limpio</code>	<code>:= float(str(valor_declarado_ars).replace("ARS", "").replace("\$", "").replace(" ", ""))</code>
<code>es_fin_de_semana</code>	<code>:= "Si" if dia_semana_despacho in ["sábado", "domingo"] else "No"</code>
<code>clima_adverso</code>	<code>:= "Si" if clima_despacho in ["Tormenta", "Lluvia"] else "No"</code>
<code>clima_vispera</code>	<code>:= "Si" if clima_despacho == "Tormenta" and es_vispera_feriado == "Si" else "No"</code>
<code>rango_distancia</code>	<code>:= "Corta" if distancia_km < 619.5 else "Media" if distancia_km < 1258.5 else "Alta"</code>
<code>grupo_intentos_previos</code>	<code>:= "Sin intentos" if intentos_previos < 0.5 else "Un intento" if intentos_previos < 1.5 else "Dos o mas intentos"</code>
<code>codigo_postal_valido</code>	<code>:= "Valido" if len(str(codigo_postal_dest).replace(" ", "").upper()) == 8 and str(codigo_postal_dest).replace(" ", "").upper()[0].isalpha() an</code>

La decisión de crear esta variable se basó en que el código postal original podía introducir ruido en el modelo, ya que contenía valores mal cargados, incompletos o con formatos inconsistentes. Además, utilizar el código postal completo como categoría podía generar demasiados valores distintos, dificultando la interpretación y aumentando la complejidad del modelo. Por eso, se optó por una transformación más simple: distinguir entre registros con código postal válido e inválido, con formato B1428AAA como válido.

Test and score:



Test and Score - Orange

☒ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out


☐ Test on train data

☐ Test on test data

Evaluation results for target 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.640	0.713	0.312	0.295	0.331	0.132
Logistic Regression	0.706	0.664	0.407	0.311	0.589	0.223
Naive Bayes	0.696	0.790	0.342	0.445	0.277	0.234

Predictions:



☒ Show performance scores

Target class: 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.643	0.711	0.331	0.316	0.347	0.147
Logistic Regression	0.705	0.653	0.412	0.317	0.590	0.216
Naive Bayes	0.701	0.785	0.347	0.465	0.277	0.240


Luego de incorporar **código_postal_valido**, los resultados en Test & Score mostraron una leve mejora en algunas métricas. Sin embargo, en Predictions los

resultados se mantuvieron prácticamente iguales respecto de la versión anterior. Esto indica que la variable puede aportar cierta información en la validación cruzada, pero no generó una mejora significativa sobre el conjunto de test.

Prueba 6:


Nuevas variables **rango_distancia** y **grupo_intentos_previos**:

Como última prueba para mejorar el **Recall de la clase 1**, se utilizaron los resultados del análisis exploratorio realizado con **Mosaic Display**. En primer lugar, se observó la variable **distancia_km**, donde los rangos de mayor distancia mostraban una proporción relativamente más alta de entregas demoradas.



A partir de este patrón, se construyó la variable **rango_distancia**, dividiendo la distancia en tres categorías: corta, media y alta. Luego, se incorporó al modelo específicamente la categoría **rango_distancia = Alta**, ya que concentraba los rangos donde visualmente se observaba mayor proporción de demoras.

En segundo lugar, se analizó la variable **intentos_previos**. En el Mosaic Display se observó que la segunda columna, correspondiente a un intento previo, mostraba una proporción mayor de entregas demoradas en comparación con otros grupos.



Por eso, se creó la variable **grupo_intentos_previos**, que agrupa los casos en: sin intentos, un intento, y dos o más intentos. Para el modelo se incluyó la categoría **grupo_intentos_previos = Un intento**, con el objetivo de capturar ese patrón observado durante el EDA.

Esta prueba se complementó con la selección de otras variables y categorías de anteriores pruebas que habían mostrado mayor relación visual con el target, como **provincia_destino = Córdoba**, **provincia_destino = Buenos Aires**, **proveedor_logistico = Transporte Propio**, **algunos días de despacho** y **condiciones climáticas**. De esta manera, el modelo quedó construido con variables seleccionadas a partir de patrones observados en el análisis exploratorio, reduciendo parte del ruido de categorías que no aportaban diferencias significativas.

Features (16)

Filter

N

provincia_destino=Córdoba

N

provincia_destino=Buenos Aires

N

dia_semana_despacho=jueves

N

es_fin_de_semana=Sí

N

es_fin_de_semana=No

N

es_vispera_feriado=Sí

N

es_vispera_feriado=No

N

proveedor_logistico=Transporte Propio

N

dia_semana_despacho=domingo

N

clima_despacho=Lluvia

N

clima_despacho=Tormenta

N

clima_despacho=Despejado

N

proveedor_logistico=Correo Argentino

N

rango_distancia=Alta

N

grupo_intentos_previos=Un intento

N

codigo_postal_valido=Valido

Target (1)

C

entrega_demorada

Metas (4)

N

id_pedido

S

fecha_despacho

S

codigo_postal_dest

S

valor_declarado_ars

Resultados:

Test and score:

Test and Score - Orange

☒ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Evaluation results for target 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.640	0.676	0.366	0.297	0.476	0.172
Logistic Regression	0.693	0.675	0.411	0.319	0.577	0.229
Naive Bayes	0.691	0.794	0.333	0.457	0.262	0.233

Predictions:

☒ Show performance scores Target class: 1


Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.650	0.700	0.381	0.332	0.449	0.193
Logistic Regression	0.701	0.673	0.427	0.334	0.592	0.240
Naive Bayes	0.700	0.788	0.333	0.473	0.257	0.235

En comparación con la prueba anterior, los resultados de **Predictions** muestran una mejora en los modelos principales. Random Forest aumentó su Recall de aproximadamente **0.347 a 0.444**, lo que indica que logró detectar una mayor proporción de entregas demoradas reales. Logistic Regression también mejoró levemente, pasando de un Recall de **0.590 a 0.592**, pero además aumentó su F1-score de **0.412 a 0.427** y su MCC de **0.216 a 0.240**, lo que indica una mejora más equilibrada en el desempeño general del modelo.

En **Test and Score**, los resultados no mejoraron de forma uniforme en todos los modelos. Sin embargo, en el conjunto de Predictions, que permite observar el comportamiento sobre el set separado para test, sí se evidenció una mejora parcial, especialmente en Random Forest y Logistic Regression.

Prueba 7:

Eliminación de Outliers:



Mediante el uso del Widget Outliers, se ignoraron los Outliers del dataset para verificar si representaban ruido para el modelo y así poder mejorar las métricas.

Resultados:

Test and Score:

Test and Score - Orange

☒ Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Evaluation results for target 1

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.638	0.678	0.365	0.298	0.473	0.172
Logistic Regression	0.693	0.675	0.411	0.319	0.577	0.229
Naive Bayes	0.691	0.794	0.333	0.457	0.262	0.233

Predictions:

☒ Show performance scores Target class: 1						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.654	0.699	0.388	0.334	0.464	0.200
Logistic Regression	0.701	0.673	0.427	0.334	0.592	0.240
Naive Bayes	0.700	0.788	0.333	0.473	0.257	0.235

Resultados:

Se observa que el uso del widget Outliers prácticamente no modificó el desempeño general de los modelos. En Logistic Regression y Naive Bayes, las métricas se mantuvieron exactamente iguales tanto en Test and Score como en Predictions, por lo que el tratamiento de Outliers no tuvo impacto sobre estos modelos.

El único modelo que mostró variaciones fue Random Forest, aunque los cambios fueron muy leves. En Test and Score, sus métricas se mantuvieron casi estables: el AUC bajó apenas de 0.640 a 0.638, el CA subió de 0.676 a 0.678 y el Recall bajó levemente de 0.476 a 0.473. En cambio, en Predictions sí se observa una pequeña mejora en varias métricas: el AUC pasó de 0.650 a 0.654, el F1 de 0.381 a 0.388, el Recall de 0.449 a 0.464 y el MCC de 0.193 a 0.200.

En conclusión, ignorar los outliers no generó un cambio relevante en el rendimiento global del pipeline. La mejora más visible aparece en Random Forest sobre Predictions, especialmente en la detección de la clase 1, pero la diferencia es muy pequeña.

ANÁLISIS DE LA MATRIZ DE CONFUSIÓN (PREDICTIONS):


Análisis de los modelos a partir de la matriz de confusión

Métricas usadas para la matriz (Prueba 6):

MÉTRICAS					
MODELO	ACCURACY	PRECISION	RECALL	F1-SCORE	AUC
Random Forest	0,702	0,338	0,464	0,391	0,652
Logistic Regression	0,673	0,334	0,592	0,427	0,701
Naive Bayes	0,788	0,473	0,257	0,333	0.700

A partir de la matriz de confusión, se compararon los tres modelos evaluados: Random Forest, Logistic Regression y Naive Bayes. El análisis se realizó sobre el conjunto de test, compuesto por 2.000 registros.

Random Forest




El modelo Random Forest clasificó correctamente 1.213 entregas a tiempo y 191 entregas demoradas. A su vez, generó 375 falsos positivos, es decir, envíos que fueron clasificados como demorados, aunque finalmente llegaron a tiempo, y 221

falsos negativos, correspondientes a entregas que sí se demoraron, pero fueron clasificadas como entregas a tiempo.

En términos de negocio, Random Forest logró detectar 191 de las 412 entregas demoradas reales, alcanzando un Recall aproximado de **0,464** para la clase 1. Esto significa que identificó cerca del 46% de las demoras reales. Si bien este resultado es mejor que el de Naive Bayes, todavía deja sin detectar más de la mitad de los casos demorados.

Su Accuracy aproximada es de **0,702**, pero como el objetivo principal no es solamente acertar en términos generales, sino detectar la mayor cantidad posible de entregas demoradas, Random Forest no resulta el modelo más conveniente frente a Logistic Regression.

Logistic Regression



El modelo Logistic Regression clasificó correctamente 1.102 entregas a tiempo y 244 entregas demoradas. También generó 486 falsos positivos y 168 falsos negativos.


Este modelo logró detectar 244 de las 412 entregas demoradas reales, alcanzando un Recall aproximado de **0,592** para la clase 1. Esto significa que identificó cerca del 59% de las demoras reales, siendo el modelo con mejor desempeño para detectar los casos que más le importan al negocio.

Si bien Logistic Regression genera una mayor cantidad de falsos positivos, este costo se considera aceptable en el contexto del problema. Un falso positivo puede implicar enviar una alerta o compensación innecesaria, pero un falso negativo

implica no avisarle al cliente sobre una demora real. Por eso, aunque la Accuracy del modelo sea menor, aproximadamente **0,673**, su mayor Recall lo vuelve más útil para una estrategia preventiva.

Además, Logistic Regression obtuvo un F1-score aproximado de **0,427** para la clase 1, lo que muestra que mantiene el mejor equilibrio entre detección de demoras y precisión de las alertas dentro de los modelos evaluados.

Naive Bayes



El modelo Naive Bayes clasificó correctamente 1.470 entregas a tiempo y 106 entregas demoradas. También generó 118 falsos positivos y 306 falsos negativos.

A primera vista, Naive Bayes presenta la mayor Accuracy, con un valor aproximado de **0,788**, y también la mejor Precision para la clase 1, cercana a **0,473**. Esto significa que, cuando el modelo predice una demora, tiene una proporción relativamente alta de aciertos.

Sin embargo, su principal debilidad es el bajo Recall. Naive Bayes solo detectó 106 de las 412 entregas demoradas reales, alcanzando un Recall aproximado de **0,257**. En otras palabras, dejó sin detectar casi tres cuartas partes de las demoras reales. Desde el punto de vista del negocio, esto lo vuelve menos adecuado, porque no cumple con el objetivo principal de anticipar la mayor cantidad posible de retrasos.

MATRIZ DE CONFUSIÓN				
MODELO	VERDADEROS NEGATIVOS	FALSOS POSITIVOS	FALSOS NEGATIVOS	VERDADEROS POSITIVOS
Random Forest	1213	375	221	191
Logistic Regression	1102	486	168	244
Naive Bayes	1470	118	306	106

Selección del modelo final

En función de la matriz de confusión, el modelo elegido es **Logistic Regression**. Esta decisión se justifica porque es el modelo que mejor responde al objetivo principal del negocio: detectar la mayor cantidad posible de entregas demoradas.

Aunque Naive Bayes obtuvo la mayor Accuracy y la mejor Precision, su Recall fue demasiado bajo, por lo que dejó pasar muchas entregas demoradas sin detectar. Random Forest mostró un desempeño intermedio, con mejor Recall que Naive Bayes, pero inferior al de Logistic Regression.

Logistic Regression, en cambio, alcanzó el mayor Recall para la clase demorada, con un valor aproximado de **0,592**, detectando 244 de las 412 entregas demoradas reales. Por lo tanto, se selecciona como modelo final, ya que prioriza la reducción de falsos negativos, que son el error más costoso para el negocio. En este caso, es preferible aceptar una mayor cantidad de falsas alarmas antes que no advertir a clientes cuyos envíos efectivamente se van a demorar.


INTERPRETACIÓN

ETAPA 7

Para poder interpretar al modelo y entender preguntas como:

- ¿Qué aprendió el modelo?
- ¿Qué variables importan más?
- ¿Se confirmaron las hipótesis del EDA?
- ¿Qué recomendaciones concretas podemos dar?

Analizamos el Nomogram conectado al modelo ganador, Logistic Regression.



Se observa que las variables con mayor peso en la predicción de demoras son **clima_despacho = Tormenta**, **rango_distancia = Alta** (una de las variables derivadas creadas a partir de **distancia_km**) y **es_vispera_feriado = Sí**. Esto indica que el modelo identifica como factores relevantes aquellas condiciones que pueden aumentar la complejidad operativa del envío.

En primer lugar, la presencia de tormenta aparece como una de las variables más importantes, lo cual resulta coherente con el análisis exploratorio previo. Las

condiciones climáticas adversas pueden afectar rutas, tiempos de traslado, disponibilidad de transporte y operación de reparto.

En segundo lugar, la variable **rango_distancia = Alta** también presenta un peso relevante, entendiendo que las distancias mas largas son un factor que afecta la entrega debido a la dificultad de calcular el tiempo que va a tardar el pedido en llegar por las contingencias posibles.

Por último, la variable **es_vispera_feriado** también aparece entre las más importantes del modelo. Esto sugiere que los despachos realizados en días cercanos a feriados pueden tener mayor riesgo de demora, posiblemente por menor disponibilidad operativa, acumulación de pedidos o restricciones en la distribución.

Respecto a las hipótesis planteadas en el EDA, esta captura sirve para decir que el modelo **confirma bastante bien las tres hipótesis:**

H1- Los envíos con mayor distancia km tienen mayor probabilidad de sufrir una demora.

H2- Los envíos despachados en días de tormenta tienen mayor probabilidad de demorarse que los enviados con clima despejado o lluvia.

H3- Los envíos despachados en víspera de feriado tienen mayor probabilidad de presentar demora.

RECOMENDACIONES:

A partir de los hallazgos del modelo, se proponen tres recomendaciones concretas de negocio:

En primer lugar, se recomienda activar alertas preventivas para los envíos despachados en días de tormenta. Dado que el clima adverso aparece como una de las variables más relevantes del modelo, la empresa podría utilizar esta información para anticiparse a posibles retrasos y enviar comunicaciones proactivas al cliente antes de que se genere un reclamo.

En segundo lugar, se recomienda priorizar el seguimiento operativo de los envíos de larga distancia. Deberían monitorear con mayor frecuencia estos envíos, revisar su trazabilidad y anticipar posibles problemas en el recorrido.

En tercer lugar, se recomienda reforzar la planificación logística en vísperas de feriado. La empresa podría tomar medidas preventivas en esos días, como aumentar la capacidad operativa, coordinar mejor con los proveedores logísticos

o ajustar las promesas de entrega. Esto permitiría reducir el riesgo de incumplimiento y mejorar la experiencia del cliente.

Estas recomendaciones permiten traducir los resultados del modelo en acciones concretas. En lugar de usar el modelo únicamente como una herramienta técnica de predicción, la empresa podría incorporarlo como apoyo para la toma de decisiones operativas, priorizando recursos en los envíos con mayor probabilidad de demora.

Hallazgo sorprendente o contraintuitivo:

Un hallazgo contraintuitivo del modelo es que la variable **es_fin_de_semana=Sí** presenta una importancia baja dentro del Nomograma, a pesar de que intuitivamente podría esperarse que los fines de semana estén más asociados a retrasos logísticos. En principio, podría suponerse que una menor actividad operativa o menor disponibilidad de transporte durante esos días aumentaría la probabilidad de demora. Sin embargo, el modelo no le asigna un peso relevante a esta variable.

Este resultado sugiere que el hecho de que un despacho ocurra en fin de semana no es, por sí solo, un factor determinante de demora. En cambio, el modelo parece otorgar mayor importancia a condiciones más específicas del contexto logístico, como **clima_despacho=Tormenta, rango_distancia=Alta y es_vispera_feriado=Sí**. Incluso variables más puntuales, como **dia_semana_despacho=domingo**, parecen aportar más información que la categoría amplia de fin de semana.

Desde el punto de vista del negocio, este hallazgo es relevante porque indica que las acciones preventivas no deberían activarse simplemente por tratarse de un fin de semana, sino en función de factores operativos más concretos y con mayor capacidad predictiva.

